

# Trabalho Final

**ME613 - Análise de Regressão**

**Professora: Tatiana Benaglia**

Lorena Baquete Marini - 198483

Brenda Luiza Correa - 216037

Vitória Linda da Silva Oliveira - 212826

Paula Liserre Calabrez - 242782

# Mínimos Quadrados Ponderados

- Introdução
- Motivação
- Metodologia
- Aplicação a um conjunto de dados
- Bibliografia

# Introdução

O método de Mínimos Quadrados Ponderados (MQP) é uma técnica para estabilizar a variância de um modelo de regressão quando as observações são independentes e as variâncias desiguais.

É adequado para minimizar a soma dos quadrados quando um modelo de regressão linear apresenta uma grande variabilidade dos erros.

# Compreendendo o uso dos Mínimos Quadrados Ponderados

## Presuposto da Regressão Linear Múltipla

$$Y = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_{p-1} X_{i,p-1} + \varepsilon_i$$



A variância da variável dependente,  $Y$ , deve ser constante para os valores das variáveis preditoras  $X_1, X_2, \dots, X_{p-1}$ .



Os erros do modelo (resíduos) devem ser constantes, independente dos valores da variável resposta ( $Y$ ).



# Homocedasticidade



× FAILED

# Heterocedasticidade

**Ou seja, quando não acontece, diz-se que os dados apresentam heterocedasticidade**



A HOMOSCEDASTICIDADE É NECESSÁRIA PARA ESTIMAR OS TESTES DE T E F, ALÉM DOS INTERVALOS DE CONFIANÇA.

Então, vamos discorrer sobre as consequências da heterocedasticidade para a estimação de **Mínimos Quadrados Ordinários** e trazer soluções para a ocorrência de heterocedasticidade utilizando **Mínimos Quadrados Ponderados**.

# HETEROSCEDASTIDADE


**No cenário de heteroscedastidade, os estimadores de variância são viesados.**

Então, como os erros-padrão dos estimadores de Mínimos Quadrados Ordinários (MQO) dependem diretamente dessas variâncias, eles **não são mais apropriados** para a construção de testes e intervalos de confiança estatísticas  $t$  e  $F$ .



**Precisamos, portanto,  
obter estimadores de variância  
que sejam válidos na presença  
de heterocedasticidade. Para  
isso, usaremos o método dos  
Mínimos Quadrados Ponderados  
(MQP)**

Comparativamente a outros métodos de correção da heterocedasticidade, como a **transformação de Box-Cox**, o MQP se destaca pela sua eficiência sem demandar uma transformação específica dos dados. Ao preservar a interpretação dos coeficientes do modelo original, o MQP oferece resultados mais diretos e interpretáveis.



**MQP PRESERVA A  
INTERPRETAÇÃO DOS  
COEFICIENTES DO  
MODELO ORIGINAL**



# Metodologia

Como vimos anteriormente, o Método dos Mínimos Quadrados Ponderados aborda casos em que os erros têm variância heterogênea, ou seja, a variância não é constante.

- Modelo de regressão múltipla:

$$Y = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_{p-1} X_{i,p-1} + \varepsilon_i$$

- Matriz de variância e covariância:  $\sigma^2(\varepsilon) = \begin{bmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_n^2 \end{bmatrix}$

Vamos considerar três casos para as estimativas de regressão: Variâncias dos erros  $\sigma_i^2$  são conhecidas, Variâncias dos Erros Conhecidas até uma Constante de Proporcionalidade e Variância dos erros desconhecida.

## 1. Variância dos Erros conhecida

Neste caso, usa-se o Método da Máxima Verossimilhança para obter estimadores dos coeficientes no modelo de regressão

$$L(\beta) = \left[ \prod_{i=1}^n \left( \frac{w_i}{2\pi} \right)^{1/2} \right] \exp \left[ -\frac{1}{2} \sum_{i=1}^n w_i (Y_i - \beta_0 X_{i1} - \dots - \beta_p X_{i,p-1})^2 \right]$$

em que  $w_i = 1/\sigma_i^2$ . Desse modo,  $w_i$  está inversamente relacionado com a variância  $\sigma_i^2$ .

# Metodologia

## 1. Variância dos Erros conhecida

Como  $w_i$  depende das variâncias dos erros, ele é conhecido, desse modo, maximizar  $L(\beta)$  é o mesmo que maximizar o termo exponencial em relação aos coeficientes de regressão:  $Q_w = \sum_{i=1}^n w_i (Y_i - \beta_0 - \beta_1 - \beta_{p-1} X_{i,p-1})^2$  sendo  $Q = (Y - Xb)' W (Y - Xb)$  em que  $W$  é uma matriz diagonal contendo os pesos  $w_i$ .

Vetor dos coeficientes de regressão estimados:

$$(X'WX) \hat{\beta}_w = X'WY, \text{ portanto } \hat{\beta}_{w_{p \times 1}} = (X'WX)^{-1} X'WY.$$

# Metodologia

## 1. Variância dos Erros conhecida

Temos que a esperança e variância são:  $E[\hat{\beta}] = \beta$  e  $Var(\hat{\beta}) = K\sigma_i^2 K^T$ . tomamos  $\Sigma = \sigma_i^2$  e  $K = (X'WX)^{-1}X'W$ , então  $Var(\hat{\beta}) = K\Sigma K^T = [(X^T\Sigma^{-1}X)^{-1}X^T\Sigma^{-1}]\Sigma[\Sigma^{-1}X(X^T\Sigma^{-1}X)^{-1}] = (X^T\Sigma^{-1}X)^{-1}$

Como  $w_i = 1/\sigma_i^2$ , é possível inferir que a matriz de variância-covariância determinada por  $\sigma_{p \times p}^2\{\beta_w\} = (X'WX)^{-1}$

- Os estimadores dos mínimos quadrados ponderados e da máxima verossimilhança são: não tendenciosos; consistentes e têm variância mínima entre os estimadores lineares.

## 2. Variâncias dos Erros Conhecidas até uma Constante de Proporcionalidade

São conhecidas as magnitudes relativas das variâncias, assim os pesos relativos  $w_i$  são um múltiplo constante dos pesos verdadeiros desconhecidos  $1/\sigma_i^2$ , sendo  $w_i = k(1/\sigma_i^2)$ .  $W$  continua a ser a matriz diagonal contendo os pesos  $w_i$ , e portanto, esses pesos e  $W$  são conhecidos.

Os parâmetros de regressão continuam sendo estimados através da equação:

$$\hat{\beta}_w = (X'WX)^{-1}X'WY$$

Isso ocorre porque estimadores dos mínimos quadrados ponderados e de máxima verossimilhança não são afetados pela constante  $k$

## 2. Variâncias dos Erros Conhecidas até uma Constante de Proporcionalidade

A matriz de variância-covariância passa a ser:  $\sigma_{pxp}^2\{\beta_w\} = k(X'WX)^{-1}$  e é desconhecida, porém pode ser estimada como o erro quadrático médio ponderado (MSE):

$$\hat{k} = \frac{\sum w_i (Y_i - \hat{Y}_i)^2}{n-p} = \frac{\sum w_i e_i^2}{n-p}$$

Então, basta substituir a estimativa de  $k$  em  $\sigma_{pxp}^2\{\beta_w\}$  para estimar  $Var(\hat{\beta})$

# Metodologia

## 3. Variância Desconhecida

Para o último caso é necessário usar estimativas das variâncias, que podem ser obtidas de diversas maneiras. Abordaremos dois métodos de obtenção de estimativas das variâncias de  $\sigma_i^2$ :

# Metodologia

## Estimativa da Função de Variância ou Função de Desvio Padrão

A variância do termo de erro  $\varepsilon_i^2$  pode ser expressa da seguinte forma:

$$\sigma_{\varepsilon_i}^2 = E\{\varepsilon_i^2\} - (E\{\varepsilon_i\})^2 = E\{\varepsilon_i^2\}, \text{ uma vez que } E\{\varepsilon_i\} = 0.$$

Assim, podemos estimar a função de variância descrevendo a relação de  $\sigma_{\varepsilon_i}^2$  com as variáveis preditoras relevantes, primeiro ajustando o modelo usando MQO, em seguida regressando os resíduos ao quadrado em relação à variável preditora apropriada.



# Metodologia

## Estimativa da Função de Variância ou Função de Desvio Padrão

Uso de algumas possíveis funções de variância e desvio padrão:

- Um gráfico residual em relação a  $X_1$  exibe uma forma de megafone. Regresse os resíduos absolutos contra  $X_1$ .
- Um gráfico residual em relação a  $\hat{Y}$  exibe uma forma de megafone. Regresse os resíduos absolutos contra  $\hat{Y}$ .
- Um gráfico dos resíduos em relação a  $X_2$  sugere que a variância aumenta rapidamente com o aumento de  $X_2$  até um ponto e depois aumenta mais lentamente. Regresse os resíduos absolutos contra  $X_2$  e  $X_2^2$ .
- Obtemos os pesos estimados:  $w_i = \frac{1}{(\hat{s}_i)^2}$  ou  $w_i = \frac{1}{\hat{v}_i}$  que constituem a matriz diagonal  $W$ .

# Metodologia

## Uso de Repetições ou Quase Repetições

Utilizado em experimentos planejados onde observações replicadas são feitas em cada combinação dos níveis das variáveis preditoras.

Se o número de replicatas for grande, os pesos  $W_i$  podem ser obtidos diretamente das variâncias amostrais.

Caso contrário, as variâncias ou desvios padrão amostrais devem ser regredidos contra variáveis preditoras apropriadas para estimar a função de variância ou desvio padrão, a partir da qual os pesos podem então ser obtidos.

# Dados

O conjunto de dados Preço de Casa que foi avaliado possui as seguintes variáveis:

- $Y$  = preço de venda de uma casa
- $X_1$  = metragem quadrada da casa
- $X_2$  = metragem quadrada do lote


Uma transformação de variável foi aplicada às três características por meio do logaritmo natural, resultando no modelo subsequente.

# Aplicação dos dados

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	1.96361	0.31286	6.276	7.33e-10	***
x1	1.21976	0.03401	35.867	< 2e-16	***
x2	0.11034	0.02412	4.575	5.97e-06	***
---					

Nota-se um formato "cônico" dos resíduos no gráfico, o que sugere a presença de heterocedasticidade.



# Aplicação dos dados

O modelo foi ajustado novamente:


- 1- Calcule os valores absolutos dos resíduos do MQO;
- 2 - Regresse os valores absolutos dos resíduos de MQO versus os valores ajustados de MQO;
- 3 - Calcule pesos iguais a  $1/\text{fits}^2$ , onde "fits" são os valores ajustados da regressão na última etapa.
- 4 - Em seguida, reajuste o modelo de regressão original, mas desta vez use esses pesos em uma regressão de mínimos quadrados ponderados (MQP).

# Aplicação dos dados

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	2.37671	0.28367	8.379	5.04e-16
x1	1.20136	0.03363	35.721	< 2e-16
x2	0.08308	0.02169	3.830	0.000144

Neste novo gráfico podemos ver que os resíduos não seguem mais nenhuma tendência.



# Aplicação dos dados

```
fit <- lm(formula = log(y) ~ x1 + x2)
#1 - Calculando os valores absolutos dos resíduos do mínimos
quadrados ordinários
fit_res <- residuals(fit)
abs_res <- abs(fit_res)

#2 - Regressando os valores absolutos dos resíduos de Mínimos
quadrados ordinários (MQO) versus os valores ajustados de MQO -
esses valores ajustados são estimativas dos desvios padrão dos
erros
fit_values <- fitted(fit)
abs_resid_model <- lm(abs_res ~ fit_values)

#3 - Calculando pesos iguais a  $1/\text{fits}^2$ , sendo "fits" os valores
ajustados da regressão na última etapa;
fitted_values_abs_resid <- fitted(abs_resid_model)
weights <-  $1/(\text{fitted\_values\_abs\_resid})^2$ 

#4 - Em seguida, reajustando o modelo de regressão original, mas
desta vez usando esses pesos em uma regressão de mínimos
quadrados ponderados (MQP).
fit2 <- lm(formula = log(y) ~ x1 + x2, weights = weights)
residuals_wls <- resid(fit2)
```

# Obrigada pela atenção!

Lorena Baquete Marini - 198483

Brenda Luiza Correa - 216037

Vitória Linda da Silva Oliveira - 212826

Paula Liserre Calabrez - 242782